



université
PARIS-SACLAY

Master 2 Innovation, Marché et Sciences des Données

RAPPORT DU PROJET DE SCORING

Modélisation et optimisation d'un score de risque de crédit : Estimation de la probabilité de défaut par approches statistiques et Machine Learning

Rédigé par :

KOURAOGO Emmanuel

Encadrant :

TOURE Ibrahim

Année universitaire 2025-2026

TABLES DE MATIERES

INTRODUCTION.....	1
I. PARTIE 1: DIAGNOSTIC ET FIABILISATION DES DONNÉES	2
1. Audit de la qualité des données et conséquences stratégiques.....	2
2. Analyse structurelle des valeurs manquantes (dendrogramme).....	4
3. Imputation robuste par la méthode MICE (PMM).....	6
II. PARTIE 2 : ANALYSE EXPLORATOIRE ET SÉLECTION DES DRIVERS	7
1. Analyse exploratoire descriptive.....	7
2. Validation du pouvoir discriminant : Tests paramétriques et non-paramétriques	9
3. Analyse des associations : Khi-deux et ANOVA	11
4. Hiérarchisation du pouvoir prédictif : Information Value (IV)	14
III. PARTIE 3 : MODÉLISATION LOGISTIQUE ET CONSTRUCTION DU SCORE	16
1. Modélisation logistique et interprétation des facteurs de risque (Odds Ratios).....	16
2. Diagnostic de l'adéquation du modèle : discrimination (AUC) vs. Calibrage (Hosmer-Lemeshow).....	18
3. Construction du score cartographique (PDO) et analyse discriminante par déciles	20
IV. PARTIE 4 : VALIDATION CROISÉE ET APPROFONDISSEMENTS.....	24
1. Optimisation du seuil de décision pour l'arbitrage des risques	24
2. Analyse non-linéaire du risque : Arbre de décision	26
V. PARTIE 5 : MODÉLISATION PRÉDICTIVE COMPARATIVE	28
1. Traitement du déséquilibre des classes par SMOTE.....	28
2. Benchmark des algorithmes : Régression Logistique, Arbre, Gradient Boosting, XGBoost.....	29
3. Évaluation des performances : AUC-ROC, Recall, Matrices de confusion.....	32
4. Interprétation des modèles et analyse de l'importance des variables	33
CONCLUSION ET PERSPECTIVES	35
ANNEXES	i

INTRODUCTION

Dans l'environnement bancaire contemporain, la maîtrise du risque de crédit ne représente plus seulement un rempart contre les pertes financières, mais constitue un pilier central de la stratégie réglementaire imposée par les accords de Bâle III et la norme IFRS 9. La capacité d'un établissement à quantifier avec précision la Probabilité de Défaut (PD) est désormais une exigence stricte, imposant une rigueur méthodologique sans faille dans la conception des modèles de notation interne.

Le présent rapport s'appuie sur le jeu de données HMEQ (Home Equity), référence de l'industrie regroupant 5 960 demandes de prêts caractérisées par une variable cible binaire (BAD) et 12 prédicteurs capturant tant le profil patrimonial que l'historique comportemental des emprunteurs. Puisque le taux de défaut observé s'élève à 19,8 %, ce portefeuille est représentatif d'un segment « non-prime » exigeant une analyse discriminante particulièrement fine pour séparer les dossiers sains des profils à risque.

Le cœur de ce projet repose sur une interrogation méthodologique et technologique majeure : Comment construire un modèle de scoring performant, robuste et interprétable, en mobilisant de manière complémentaire les trois environnements SAS, R et Python ?

Pour répondre à cette problématique de scoring multi-environnement, notre analyse s'articule autour d'une progression logique visant à transformer une donnée brute et lacunaire en un outil de décision robuste.

Dans un premier temps, l'effort s'est porté sur la fiabilisation de l'information, étape cruciale au regard des fragilités méthodologiques identifiées lors du diagnostic initial. Une attention particulière a été accordée au ratio d'endettement (DEBTINC), point critique présentant un taux d'omission de 26,99 %. Afin de restaurer l'intégrité du jeu de données sans introduire de biais de sélection massif, nous avons implémenté une méthode d'imputation sophistiquée par Predictive Mean Matching (PMM). Une fois cette base de données consolidée, l'étude s'est concentrée sur l'identification des déterminants du risque. Cette phase a permis de hiérarchiser les leviers fondamentaux du défaut en s'appuyant sur des tests statistiques rigoureux, tels que l'ANOVA et le Khi-deux, complétés par l'analyse de l'Information Value (IV) pour isoler les variables les plus discriminantes.

Par la suite, l'architecture de ce travail a reposé sur la recherche d'une convergence technologique et le déploiement du Machine Learning. Pour surpasser les limites inhérentes aux modèles linéaires, nous avons confronté la Régression Logistique à des algorithmes de pointe tels que le Gradient Boosting et XGBoost. Afin de garantir l'équité de l'apprentissage face au déséquilibre natif des classes, la technique SMOTE a été mobilisée pour stabiliser le jeu d'entraînement à une proportion de 50 % de défauts.

Enfin, l'aboutissement de ce processus réside dans l'aide à la décision opérationnelle, où la rigueur statistique rencontre les besoins métiers. Cette ultime étape a permis de construire une cartographie visuelle du risque via l'Arbre de Décision, tout en validant la performance de nos modèles à travers les métriques d'AUC-ROC et de Recall. Ce parcours analytique complet assure ainsi la fourniture d'un score auditable, capable d'arbitrer avec agilité entre le développement commercial et la sécurité financière.

I. PARTIE 1: DIAGNOSTIC ET FIABILISATION DES DONNÉES

1. Audit de la qualité des données et conséquences stratégiques

L'examen préliminaire du fichier HMEQ révèle une structure de données riche, mais grevée par des fragilités méthodologiques majeures qui imposent une vigilance extrême avant toute modélisation. Il apparaît que la qualité du score final sera directement corrélée à la pertinence de nos choix de traitement de ces données "bruyantes", à commencer par la variable DEBTINC. Cette dernière représente le point le plus critique du diagnostic avec un taux d'omission alarmant de 26,99 %. Opérationnellement, cela signifie qu'une information cruciale sur la capacité de remboursement manque pour plus d'un quart des demandeurs, ce qui rend l'exclusion pure et simple de ces dossiers inenvisageable sous peine d'introduire un biais de sélection massif. En effet, l'absence de déclaration du ratio d'endettement est souvent corrélée à un profil de risque spécifique, et une suppression affaiblirait la représentativité du modèle sur le segment « non-prime ».

Cette problématique de données manquantes s'étend également aux variables comportementales telles que DEROG et DELINQ, qui affichent des taux de non-réponse de 13,48 % et 10,78 % respectivement. Ces manques soulèvent une difficulté de type "données non manquantes de manière aléatoire" (MNAR), car dans l'industrie du crédit, un champ d'incident non renseigné est souvent interprété par erreur comme une absence d'incident. Or, une telle confusion risquerait de conduire à une sous-estimation systématique du risque de défaut, lequel reste pourtant marqué par un taux de 19,8 % sur l'échantillon total. Par ailleurs, les variables de stabilité et de patrimoine comme MORTDUE et YOJ, bien que mieux renseignées avec environ 9,5 % de manquants, présentent des volatilités qui exigent un nettoyage rigoureux. On observe notamment pour l'ancienneté de l'emploi (YOJ) une moyenne de 8,9 ans, mais avec des valeurs s'étendant jusqu'à 41 ans, ce qui témoigne d'une grande hétérogénéité des profils. De même, la variable CLAGE, affichant une moyenne de 179,7 mois, contient des anomalies de saisie aberrantes allant jusqu'à 1 168 mois (97 ans), lesquelles pourraient fausser la pente de la régression logistique si elles ne sont pas plafonnées par une méthode de winsorisation.

En parallèle, l'analyse des montants engagés à travers les variables LOAN (moyenne de 18 608 \$) et VALUE (moyenne de 101 776 \$) souligne une diversité de projets financiers dont la cohérence doit être préservée. La variable NINQ, avec 9,36 % de données manquantes, ainsi que CLNO, complètent ce tableau en apportant une dimension sur la sollicitation récente de crédit et l'étendue de l'historique financier. Si l'ensemble de ces défauts de données n'est pas traité par une stratégie d'imputation sophistiquée, les conséquences pour l'établissement seraient doubles : d'une part, une instabilité du score le rendant trop sensible aux variations mineures, et d'autre part, un déficit de pouvoir discriminant qui échouerait à identifier les dossiers à haut risque. Le diagnostic est donc sans appel : si la richesse du dataset permet de construire un score performant, la complexité des données exige de dépasser les méthodes de traitement simplistes pour garantir un modèle de production auditable et stable.

Tableau 1: Statistiques descriptives et proportion des valeurs manquantes avant imputation

VALEURS MANQUANTES AVANT IMPUTATION							
Variable	N	NMiss	Mean	StdDev	Min	Max	pct_missing
LOAN	5960	0	18608	11207	1100.000000	89900	0.0000
MORTDUE	5442	518	73761	44458	2063.000000	399550	9.5186
VALUE	5848	112	101776	57386	8000.000000	855909	1.9152
YOJ	5445	515	8.922268	7.573982	0	41.000000	9.4582
DEROG	5252	708	0.254570	0.846047	0	10.000000	13.4806
DELINQ	5380	580	0.449442	1.127266	0	15.000000	10.7807
CLAGE	5652	308	179.766275	85.810092	0	1168.233561	5.4494
NINQ	5450	510	1.186055	1.728675	0	17.000000	9.3578
CLNO	5738	222	21.296096	10.138933	0	71.000000	3.8689
DEBTINC	4693	1267	33.779915	8.601746	0.524499	203.312149	26.9977

Source : Base de données HMEQ, traitements réalisés par les auteurs sous SAS.

Lecture : pct_missing correspond au pourcentage de valeurs manquantes par variable.

2. Analyse structurelle des valeurs manquantes (dendrogramme)

L'examen du dendrogramme des valeurs manquantes permet de rejeter l'hypothèse d'un mécanisme de type MCAR (Missing Completely At Random) au profit d'une structuration plus complexe des données. En effet, l'émergence de clusters distincts démontre que l'absence de données n'est pas distribuée de manière aléatoire mais suit des schémas de corrélation spécifiques.

D'une part, la proximité immédiate de variables telles que DELINQ et NINQ, ou encore CLAGE et CLNO, met en évidence un mécanisme de type MAR (Missing At Random). Cette configuration suggère que la non-réponse sur un indicateur est conditionnée par l'absence d'information sur son voisin de cluster, révélant ainsi une dépendance structurelle dans la collecte des données. À l'opposé de cette synergie, la variable DEBTINC se distingue par une hauteur d'agrégation exceptionnellement élevée, ce qui l'isole du reste du dataset. Ce

comportement atypique, corrélé aux réalités du métier du crédit, laisse suspecter un mécanisme MNAR (Missing Not At Random), car l'omission du taux d'endettement est souvent liée à la valeur même de la variable, les profils les plus risqués étant statistiquement moins enclins à fournir cette information financière critique.

Par ailleurs, le bloc situé à la base du graphique, comprenant JOB, REASON, BAD et LOAN, affiche une hauteur proche de zéro, attestant soit d'une complétude quasi totale, soit d'un pattern de manques parfaitement identique. Cette stabilité contraste avec la fragmentation du reste du dendrogramme, ce qui rend la stratégie de suppression par liste (Listwise deletion) inappropriée. Puisque le volume de données manquantes sur des variables pivots comme DEBTINC entraînerait une perte de représentativité supérieure à 25 % du dataset initial, il est impératif de privilégier des méthodes de traitement plus sophistiquées.

Dès lors, la stratégie d'imputation doit s'adapter à cette architecture des manques. Si le traitement des variables catégorielles peut s'appuyer sur la création d'une modalité "Unknown" pour préserver l'information, les variables numériques exigent quant à elles une approche plus robuste. Compte tenu des corrélations mises en lumière par le dendrogramme, l'utilisation d'une imputation multiple par équations chaînées (MICE) s'impose comme la solution optimale. Cette méthode permet effectivement de respecter les relations de dépendance entre les variables tout en minimisant le biais d'estimation, garantissant ainsi la fiabilité des modélisations prédictives ultérieures.




Figure 1: Dendrogramme hiérarchique des variables selon la structure des valeurs manquantes

Source : Base de données HMEQ, traitements réalisés par les auteurs sous SAS.

3. Imputation robuste par la méthode MICE (PMM)

L'analyse exploratoire de la structure des données, appuyée par le dendrogramme des valeurs manquantes, révèle une hiérarchie claire et des regroupements significatifs (notamment entre DELINQ et NINQ), ce qui permet d'exclure l'hypothèse d'un mécanisme de manque totalement aléatoire (MCAR). La position isolée de DEBTINC en haut de la structure hiérarchique suggère un mécanisme de type MAR (Missing At Random), voire MNAR (Missing Not At Random), où l'absence d'information est elle-même porteuse d'un signal de risque. Pour pallier ce biais sans sacrifier la puissance statistique du dataset (le listwise deletion ayant été rejeté pour éviter une perte de 21 % des observations), le choix s'est porté sur l'algorithme MICE (Multivariate Imputation by Chained Equations).

Contrairement à une imputation simple par la moyenne qui écraserait la variance et biaiserait les corrélations, MICE fonctionne par un processus itératif de régressions séquentielles, utilisant la méthode PMM (Predictive Mean Matching) pour imputer des valeurs réelles basées sur des profils de "voisins" similaires. Cette approche est primordiale en risque de crédit car elle préserve la distribution multivariée et les relations non linéaires entre les variables. In fine, la comparaison des indicateurs de tendance centrale pré et post-traitement démontre que

l'imputation a stabilisé les métriques clés (médiane de DEBTINC passant de 34,81 à 35,33) tout en conservant les valeurs extrêmes critiques pour la détection du défaut, garantissant ainsi un échantillon robuste et non biaisé pour la phase de modélisation prédictive.

II. PARTIE 2 : ANALYSE EXPLORATOIRE ET SÉLECTION DES DRIVERS

1. Analyse exploratoire descriptive

Avant d'engager les tests d'hypothèses et la hiérarchisation des variables, une analyse exploratoire descriptive a été menée afin d'examiner la structure intrinsèque des distributions et les relations globales entre prédicteurs.

a. Structure générale du portefeuille

La variable cible BAD présente un taux de défaut de 19,8 % (*voir annexe 3*) , traduisant un déséquilibre modéré entre les classes. Cette configuration est cohérente avec un segment non-prime, où la discrimination entre profils sains et risqués constitue un enjeu central.

Les distributions des variables financières (LOAN, VALUE, MORTDUE, DEBTINC) révèlent une asymétrie marquée à droite, avec la présence de valeurs extrêmes élevées (*voir annexe 4 à 7*). Cette dispersion traduit une hétérogénéité significative des profils patrimoniaux au sein du portefeuille.

Les variables comportementales (DELINQ, DEROG, NINQ) présentent une forte concentration de valeurs nulles, combinée à une queue de distribution étendue (*voir annexe 8 à 10*). Cette configuration typique des données de crédit suggère que la majorité des emprunteurs présente un comportement stable, tandis qu'une minorité concentre une intensité élevée d'incidents.

L'ancienneté de la ligne de crédit la plus ancienne (CLAGE) ainsi que l'ancienneté dans l'emploi (YOJ) affichent une dispersion importante, révélant des profils d'expérience financière variés (*voir annexe 11 et 10*).

b. Structure des dépendances entre variables

La matrice de corrélation met en évidence une dépendance modérée entre certaines variables patrimoniales, notamment LOAN, VALUE et MORTDUE, ce qui est économiquement cohérent compte tenu de leur nature intrinsèquement liée au financement immobilier.

En revanche, les variables comportementales présentent des corrélations relativement faibles avec les autres prédicteurs, suggérant qu'elles apportent une information complémentaire et non redondante.

Aucune corrélation extrême susceptible d'engendrer une instabilité structurelle majeure n'est observée au sein des variables originales.




Figure 2 : Matrice de corrélation des variables numériques

Source : Base de données HMEQ, traitements réalisés par les auteurs sous python.

c. Lecture exploratoire des écarts entre groupes

L'observation visuelle des distributions par statut de défaut révèle des écarts marqués pour certaines variables comportementales et financières, en particulier pour les incidents passés et le ratio d'endettement. Ces écarts suggèrent l'existence d'une séparation naturelle entre les populations, laquelle sera formellement validée par les tests statistiques présentés dans la section suivante.

2. Validation du pouvoir discriminant : Tests paramétriques et non-paramétriques

L'étape cruciale de notre analyse exploratoire consiste à vérifier si les caractéristiques financières et comportementales des emprunteurs diffèrent significativement selon leur statut de défaut (BAD). Pour ce faire, nous avons systématiquement appliqué le test t de Student (comparaison des moyennes) et le test de Mann-Whitney (comparaison des rangs), afin de garantir la robustesse de nos conclusions face aux éventuelles non-normalités des distributions.

a. Tests d'hypothèses et robustesse

Pour chaque variable quantitative, la structure du test est la suivante :

- **Hypothèse nulle (H_0)** : Il n'existe aucune différence significative entre la moyenne (ou la distribution) de la variable pour les clients sains (BAD = 0) et les clients en défaut (BAD = 1).
- **Hypothèse alternative (H_1)** : Les deux groupes présentent des comportements distincts, signalant un pouvoir prédictif de la variable.

L'examen des résultats (Tableau « Résultats des tests de Student et Whitney ») montre une convergence quasi totale : pour la quasi-unanimité des variables (DEBTINC, YOJ, CLAGE, DELINQ, DEROG, NINQ, LOAN), les p-values sont inférieures à 0,0001. Ce constat nous permet de rejeter H_0 avec un niveau de confiance extrêmement élevé. La mention « ROBUSTE » dans nos conclusions souligne que même lorsque les hypothèses de normalité sont levées, la distinction entre les deux groupes reste statistiquement indiscutable.

b. Analyse critique des variables clés

Le ratio d'endettement (DEBTINC) et les indicateurs de comportement passé (DELINQ, DEROG) se confirment comme les prédicteurs les plus puissants, affichant des différences de moyennes particulièrement marquées. Plus intéressant encore, la variable MORTDUE (montant de l'hypothèque) présente une p-value du test de Student à 0,0425, soit proche du seuil critique de 5 %, tandis que le test de Mann-Whitney la rejette plus fermement ($p < 0,0001$). Cela indique que si la moyenne est influencée par quelques valeurs extrêmes (outliers), la distribution globale demeure un marqueur significatif du risque.

Enfin, la variable LTV (Loan-to-Value), bien que significative ($p = 0,0032$), affiche une force de discrimination moindre par rapport aux variables de flux (revenus/dettes) ou d'antécédents de paiement. En tant qu'analyste, j'en conclus que le risque dans ce portefeuille est davantage lié au comportement de crédit de l'individu et à sa charge mensuelle qu'à la seule valeur du collatéral. Ces variables « robustes » constitueront l'épine dorsale de notre fonction de score lors de la phase de modélisation logistique.

Tableau 2 : Tests d'égalité des distributions – *t* de Student et Mann-Whitney

Résultats des tests de Student et Whitney

	Variable	p_value_t	p_value_mw	conclusion
t	DEBTINC	0.0000	0.0000	ROBUSTE
t1	YOJ	0.0000	0.0000	ROBUSTE
t2	CLAGE	0.0000	0.0000	ROBUSTE
t3	DELINQ	0.0000	0.0000	ROBUSTE
t4	DEROG	0.0000	0.0000	ROBUSTE
t5	NINQ	0.0000	0.0000	ROBUSTE
t6	LTV	0.0032	0.0015	ROBUSTE
t7	LOAN	0.0000	0.0000	ROBUSTE
t8	MORTDUE	0.0425	0.0000	ROBUSTE

Source : Base de données HMEQ, traitements réalisés par les auteurs sous SAS.

3. Analyse des associations : Khi-deux et ANOVA

a. Analyse des associations qualitatives : REASON et JOB

L'évaluation de la pertinence des prédicteurs catégoriels, à travers les tests du χ^2 d'indépendance, révèle des disparités majeures quant à leur pouvoir discriminant potentiel au sein du futur score. En examinant les statistiques relatives à la variable JOB, nous observons une statistique de Pearson s'élevant à 108,80 pour 6 degrés de liberté, associée à une p-value strictement inférieure à 0,0001. Ce résultat nous permet de rejeter sans équivoque l'hypothèse nulle d'indépendance, confirmant ainsi que la catégorie socioprofessionnelle de l'emprunteur constitue un déterminant significatif du risque de crédit. Toutefois, il convient de nuancer cette significativité statistique par la lecture du V de Cramer (0,1351). Bien que la relation soit avérée, l'intensité de l'association reste modérée, suggérant que si le métier est un indicateur nécessaire, il ne saurait être le seul pilier de segmentation du risque.

Par opposition, l'analyse de la variable REASON (motif du prêt : Debt Consolidation ou Home Improvement) présente un profil statistique plus ténu. Bien que la p-value de 0,0151 demeure en deçà du seuil critique de 5 %, indiquant une dépendance statistiquement significative avec la variable cible BAD, les indicateurs d'association tels que le coefficient Phi et le V de Cramer chutent à 0,0375. Cette valeur particulièrement faible témoigne d'une influence marginale du motif de l'emprunt sur la probabilité de défaut. D'un point de vue opérationnel, cette variable apporte une valeur ajoutée limitée à la séparation des populations saines et risquées. En tant qu'analyste, ces résultats nous orientent vers une stratégie de modélisation où la variable JOB devra être traitée avec une attention particulière lors du regroupement des modalités (binning), tandis que la variable REASON pourrait être jugée secondaire, voire candidate à une exclusion si l'on privilégie la parcimonie du modèle.

Tableau 3: Tests d'indépendance entre les variables qualitatives (JOB, REASON) et le statut de défaut (BAD)

Statistiques pour la table de JOB par BAD				Statistiques pour la table de REASON par BAD			
Statistique	DDL	Valeur	Prob	Statistique	DDL	Valeur	Prob
Khi-2	6	108.8035	<.0001	Khi-2	2	8.3900	0.0151
Test du rapport de vraisemblance	6	113.2687	<.0001	Test du rapport de vraisemblance	2	8.2620	0.0161
Khi-2 de Mantel-Haenszel	1	2.5932	0.1073	Khi-2 de Mantel-Haenszel	1	4.3249	0.0376
Coefficient Phi		0.1351		Coefficient Phi		0.0375	
Coefficient de contingence		0.1339		Coefficient de contingence		0.0375	
V de Cramer		0.1351		V de Cramer		0.0375	

Source : Base de données HMEQ, traitements réalisés par les auteurs sous SAS.

b. Analyse de la variance (ANOVA) : Déterminants du taux d'endettement

L'analyse de la variable DEBTINC (Debt-to-Income ratio) constitue un enjeu majeur, car elle représente souvent le premier indicateur de la capacité de remboursement. Pour valider statistiquement les disparités observées, nous avons procédé à une série de tests de variance.

• Impact du Profil Socio-Professionnel sur l'Endettement

Dans un premier temps, l'ANOVA à un facteur a été conduite pour tester l'influence de la variable JOB sur le ratio d'endettement. L'hypothèse nulle (H_0) postule l'égalité des moyennes de DEBTINC entre toutes les catégories de métiers, tandis que l'hypothèse alternative (H_1) suppose qu'au moins une catégorie diffère significativement des autres. Les résultats affichent une statistique F de 41,49 associée à une p-value strictement inférieure à 0,0001. Ce résultat nous impose de rejeter H_0 , confirmant que le profil professionnel induit des structures d'endettement hétérogènes. Toutefois, le coefficient de détermination ($R^2 = 0,040$) indique que le métier n'explique que 4 % de la variabilité du ratio DEBTINC. Cette faible contribution suggère que, bien que statistiquement significative, la profession ne peut être utilisée isolément pour estimer la charge de la dette d'un client.

- *Modèle avec Interaction : Synergie entre Risque et Métier*

Pour affiner notre compréhension, nous avons introduit la variable cible BAD et son interaction avec JOB dans un modèle de variance croisé. Ici, l'intérêt réside dans le test de l'effet d'interaction ($BAD \times JOB$). L'hypothèse nulle (H_0) stipule que l'effet du métier sur le niveau d'endettement est identique, que le client soit en défaut ou non. Les résultats rejettent massivement cette hypothèse ($Pr > F < 0,0001$ pour l'interaction).

Cette découverte est primordiale pour notre stratégie de scoring : elle démontre que la relation entre l'endettement et le métier n'est pas uniforme. En d'autres termes, un taux d'endettement élevé peut être « normal » et soutenable pour une catégorie professionnelle donnée (ex : Professionals) tout en étant un signal d'alarme critique pour une autre (ex : Sales). L'augmentation du R^2 à près de 6 % confirme que la combinaison du statut de défaut et du métier offre une meilleure lecture de la sensibilité financière des emprunteurs.

Tableau 4: ANOVA du ratio d'endettement – Effet principal de la catégorie professionnelle (JOB) et interaction avec le défaut (BAD)

ANOVA avec modalité Unknown					
La procédure GLM					
Variable dépendante : DEBTINC					
Source	DDL	Somme des carrés	Carré moyen	Valeur F	Pr > F
Modèle	6	18553.3188	3092.2198	41.49	<.0001
Erreur	5953	443685.1094	74.5313		
Total sommes corrigées	5959	462238.4282			

R-carré	Coef de var	Racine MSE	DEBTINC Moyenne
0.040138	25.49649	8.633154	33.86016

Source	DDL	Type I SS	Carré moyen	Valeur F	Pr > F
JOB	6	18553.31882	3092.21980	41.49	<.0001

Source	DDL	Type III SS	Carré moyen	Valeur F	Pr > F
JOB	6	18553.31882	3092.21980	41.49	<.0001

Note : La modalité 'Unknown' correspond aux emplois non renseignés

ANOVA INTERACTION BAD * JOB					
La procédure GLM					
Variable dépendante : DEBTINC					
Source	DDL	Somme des carrés	Carré moyen	Valeur F	Pr > F
Modèle	13	27462.2057	2112.4774	28.89	<.0001
Erreur	5946	434776.2225	73.1208		
Total sommes corrigées	5959	462238.4282			

R-carré	Coef de var	Racine MSE	DEBTINC Moyenne
0.059411	25.25407	8.551070	33.86016

Source	DDL	Type I SS	Carré moyen	Valeur F	Pr > F
BAD	1	7793.67349	7793.67349	106.59	<.0001
JOB	6	16496.82097	2749.47016	37.60	<.0001
BAD*JOB	6	3171.71125	528.61854	7.23	<.0001

Source	DDL	Type III SS	Carré moyen	Valeur F	Pr > F
BAD	1	3009.35840	3009.35840	41.16	<.0001
JOB	6	11043.12269	1840.52045	25.17	<.0001
BAD*JOB	6	3171.71125	528.61854	7.23	<.0001

Source : Base de données HMEQ, traitements réalisés par les auteurs sous SAS.

4. Hiérarchisation du pouvoir prédictif : Information Value (IV)

L'Information Value (IV) est une métrique synthétique issue de la théorie de l'information (basée sur l'entropie) qui permet de mesurer la capacité d'une variable à discriminer les classes de la variable cible, ici les « bons » et les « mauvais » payeurs. Contrairement aux tests de corrélation classiques, l'IV évalue la force de la relation non linéaire après discrétisation des variables. Son utilisation est primordiale dans notre projet pour deux raisons : d'une part, elle permet d'écarter les variables « bruit » qui pourraient dégrader la performance du modèle par overfitting, et d'autre part, elle fournit un critère objectif pour hiérarchiser les facteurs de risque selon les standards de la littérature actuarielle.

Dans la perspective de construire un score de crédit robuste, le simple constat d'une différence de moyenne ne suffit pas ; il est impératif de quantifier la force de séparation entre les « bons » et les « mauvais » dossiers. L'analyse de l'Information Value (IV) permet précisément d'opérer cette sélection rigoureuse tout en offrant un premier niveau de validation algorithmique par la comparaison des environnements SAS et R.

a. Les Piliers du score : Variables à « Très Fort » et « Fort » pouvoir

L'indicateur DELINQ émerge sans surprise comme le prédicteur dominant. Nous observons ici une divergence technique intéressante : l'IV s'élève à 0,3756 sous R contre 0,4909 sous SAS. Cette différence s'explique par les algorithmes de binning (discrétisation) ; SAS applique une méthode plus granulaire sur les variables à forte concentration de zéros. Dans les deux cas, l'IV dépasse largement le seuil de 0,30, confirmant un prédicteur « maître » : le comportement de paiement récent est le meilleur miroir du risque futur. Il est suivi de près par DEROG (0,2133) et CLAGE (0,2120). L'ancienneté des lignes de crédit (CLAGE) affiche une convergence parfaite entre SAS et R (écart nul), validant sa stabilité comme indicateur de maturité financière. Son pouvoir discriminant « fort » est indispensable à la robustesse du modèle final.

b. Cohérence des variables de capacité financière

Le montant du prêt (LOAN) et le ratio d'endettement (DEBTINC) présentent des IV respectives de 0,1602 et 0,1278. Bien que classées en pouvoir « fort », leur contribution reste en deçà des

variables comportementales. Cela suggère que le défaut est davantage déclenché par une rupture de gestion (incidents de paiement) que par le seul poids du capital emprunté. En tant qu'analyste, je préconise de conserver VALUE (0,1018) malgré une IV plus faible, car sa stabilité inter-logicielle (écart SAS/R de 0,0005) garantit une dimension patrimoniale fiable pour l'analyse du collatéral.

c. Variables secondaires et benchmark technique

Les variables YOJ (ancienneté emploi), LTV et MORTDUE présentent des IV qualifiées de « moyennes » (entre 0,02 et 0,10). Si MORTDUE (0,0345) semble être le maillon faible, sa cohérence absolue entre les deux outils (écart de 0,0003) atteste de la fiabilité de la donnée brute. Cependant, sa faible valeur d'IV, couplée à sa corrélation avec VALUE, pourrait justifier son éviction au profit de la parcimonie du modèle afin d'éviter l'overfitting.

Tableau 5 : *Évaluation du pouvoir prédictif des variables (Information Value) – Comparaison des estimations SAS et R*

Information Value – Comparaison SAS vs R				
Analyse complète du pouvoir prédictif				
Variable	IV	Pouvoir_Predictif	IV_SAS	Ecart_SAS_R
DELINQ	0.3756	Très fort	0.4909	−0.1153
DEROG	0.2133	Fort	0.2822	−0.0688
CLAGE	0.2120	Fort	0.2118	0.0003
LOAN	0.1602	Fort	0.1617	−0.0016
NINQ	0.1456	Fort	0.1519	−0.0063
DEBTINC	0.1278	Fort	0.1278	0.0000
VALUE	0.1018	Fort	0.1013	0.0005
YOJ	0.0694	Moyen	0.0750	−0.0056
LTV	0.0436	Moyen	0.0436	0.0000
MORTDUE	0.0345	Moyen	0.0343	0.0003

Source : Base de données HMEQ, traitements réalisés par les auteurs sous SAS et R

III. PARTIE 3 : MODÉLISATION LOGISTIQUE ET CONSTRUCTION DU SCORE

1. Modélisation logistique et interprétation des facteurs de risque (Odds Ratios)

La régression logistique s'impose comme le standard de l'industrie pour le scoring de crédit car elle permet de modéliser une variable binaire, telle que le défaut ou le non-défaut, tout en garantissant que les probabilités prédites restent confinées dans l'intervalle [0 ; 1]. Contrairement à une approche linéaire classique, cette méthode modélise le logit, soit le logarithme de l'odd (la chance) de défaut, exprimé par la relation $\ln(p/(1-p))$. Dans ce cadre, le passage du coefficient β à l'Odds Ratio (OR) par la fonction exponentielle ($\exp(\beta)$) constitue l'étape clé de l'interprétation. En effet, lorsqu'un OR est supérieur à 1, la variable associée augmente mécaniquement la probabilité de défaut, tandis qu'un OR inférieur à 1 indique un facteur protecteur réduisant le risque de crédit.

Grâce au processus de sélection *Stepwise*, seules les variables présentant une significativité statistique réelle au seuil de 5 % ont été conservées, aboutissant à l'équation prédictive suivante : $\ln(P(BAD=1)/(1-P(BAD=1))) = -1,8527 + 0,0341 * DEBTINC - 0,0060 * CLAGE + 0,5853 * DELINQ + 0,4043 * DEROG + 0,1289 * NINQ + \dots - 1,1720 * JOB$

L'analyse des variables quantitatives confirme avec une grande précision les intuitions métiers. Le comportement passé de l'emprunteur, capturé par les variables DELINQ et DEROG, s'impose comme le prédicteur le plus puissant. Avec un OR de 1,796 pour les délinquances, chaque incident de paiement supplémentaire accroît le risque de défaut de 79,6 %, tandis qu'un incident dérogatoire majeur (DEROG) l'alourdit de 49,8 %. Parallèlement, la pression financière mesurée par le ratio d'endettement (DEBTINC) montre qu'un point de pourcentage supplémentaire augmente le risque de manière continue de 3,5 %. À l'inverse, l'expérience de crédit représentée par CLAGE agit comme un facteur de stabilisation, puisque son coefficient négatif valide la prime à la maturité financière et à l'ancienneté du dossier.

Pour intégrer les dimensions qualitatives, le modèle utilise le principe des modalités de référence pour comparer les profils. Ainsi, pour le motif du prêt (REASON), la consolidation de dettes (DebtCon) sert de base de comparaison, révélant que les prêts destinés à l'amélioration

de l'habitat (HomeImp) sont 29,4 % plus risqués. Concernant la catégorie professionnelle (JOB), les cadres (Mgr) constituent la référence. Les résultats soulignent que les profils commerciaux (Sales) sont les plus vulnérables avec un risque 142 % supérieur à la référence, tandis que les employés de bureau (Office) s'avèrent être les plus stables, affichant une réduction du risque de 43,3 %. Les indépendants (Self) présentent également une fragilité accrue avec un OR de 1,661, reflétant la volatilité inhérente aux revenus non-salariés.

En somme, la cohérence des signes et la forte significativité des tests de Wald démontrent la robustesse de cette architecture prédictive. En capturant simultanément l'historique comportemental, la capacité financière et la stabilité socioprofessionnelle, ce modèle constitue le socle mathématique indispensable à l'élaboration du score final.

Tableau 6 : Estimation du modèle logistique final (PMM) - Coefficients, tests de Wald et Odds Ratios

<i>Variable</i>	<i>Modalité (si catégorielle)</i>	<i>Coefficient (β)</i>	<i>Erreur standard</i>	<i>Chi² de Wald</i>	<i>p-value</i>	<i>Odds Ratio exp(β)</i>
Intercept		-1.8527	0.2233	68.8362	<.0001	0.157
DEBTINC		0.0341	0.0049	48.7241	<.0001	1.035
YOJ		-0.0092	0.0054	2.9029	0.0884	0.991
CLAGE		-0.0060	0.0005	134.4527	<.0001	0.994
DELINQ		0.5853	0.0329	316.6901	<.0001	1.796
DEROG		0.4043	0.0429	88.7158	<.0001	1.498
NINQ		0.1289	0.0195	43.9271	<.0001	1.138
LOAN		-0.0000	0.0000	30.4843	<.0001	1.000
MORTDUE		-0.0000	0.0000	10.8477	0.0010	1.000
VALUE		0.0000	0.0000	13.1650	0.0003	1.000
REASON	HomeImp	0.2574	0.0833	9.5519	0.0020	1.294
REASON	Unknown	0.4317	0.2153	4.0211	0.0449	1.540
JOB	Office	-0.5679	0.1454	15.2555	<.0001	0.567
JOB	Other	0.0888	0.1128	0.6205	0.4309	1.093
JOB	ProfEx	-0.0650	0.1301	0.2500	0.6171	0.937
JOB	Sales	0.8840	0.2515	12.3551	0.0004	2.420
JOB	Self	0.5075	0.2121	5.7240	0.0167	1.661
JOB	Unknow	-1.1720	0.2735	18.3663	<.0001	0.310

Source : Base de données HMEQ, traitements réalisés par les auteurs sous SAS et R

Note : Relation décroissante : plus le score est élevé, plus le risque est faible

2. Diagnostic de l'adéquation du modèle : discrimination (AUC) vs. Calibrage (Hosmer-Lemeshow)

L'évaluation d'un modèle de classification binaire ne saurait se réduire à un unique indicateur ; elle exige l'examen conjoint de la discrimination et du calibrage. Nos résultats présentent un contraste instructif entre ces deux dimensions, lequel trouve en partie son explication dans le déséquilibre inhérent à la variable cible.

a. Discrimination : performance du classement relatif

L'AUC atteint 0,7897, avec un intervalle de confiance à 95 % de [0,7745 ; 0,8048]. L'hypothèse nulle H_0 : « Le modèle n'a aucun pouvoir discriminant ($AUC = 0,5$) » est rejetée très nettement. Ainsi, la probabilité qu'une paire aléatoire (bon payeur, mauvais payeur) soit correctement ordonnée par le modèle est de 79 %. Cette valeur, située dans la zone haute de la catégorie « acceptable », dénote une séparation satisfaisante des populations.

b. Calibrage : adéquation des probabilités prédites

Le test de Hosmer-Lemeshow ($g = 10$) produit une statistique de 29,853 pour 8 degrés de liberté, associée à une p-value de 2×10^{-4} .

- H_0 : « Les probabilités prédites correspondent aux fréquences observées dans chaque décile »
- H_1 : « Un écart significatif existe entre prédictions et observations »

Dès lors que $p < 0,05$, nous rejetons H_0 . Le modèle présente donc un défaut de calibrage statistiquement significatif.

c. Articulation des résultats : pourquoi une bonne discrimination peut coexister avec un mauvais calibrage

Ce pattern n'a rien de contradictoire ; il traduit une dissociation entre deux apprentissages distincts. D'un côté, le modèle a correctement inféré l'ordre relatif des individus sur l'échelle du risque tels que les mauvais payeurs reçoivent systématiquement des scores plus élevés que les

bons. De l'autre côté, il échoue à restituer la valeur absolue de ces risques – un score de 0,30 ne correspond pas au taux de défaut réellement observé pour les individus ainsi classés.

Or, le déséquilibre de classes amplifie mécaniquement ce phénomène. En présence d'une cible déséquilibrée comme ici, une proportion de défauts typiquement inférieure à 20 % tels que les modèles logistiques non pénalisés tendent à produire des prédictions trop peu dispersées et trop fortement tirées vers la moyenne globale. L'examen du tableau de Hosmer-Lemeshow corrobore cette analyse : le modèle sous-estime systématiquement le risque dans les déciles 6 à 9, c'est-à-dire précisément dans la zone où se concentre l'incertitude décisionnelle. Il prédit trop peu de défauts là où le risque est modéré à élever.

Notre modèle se comporte à l'image d'un thermomètre qui classerait sans erreur les patients fiévreux des non-fiévreux, mais afficherait obstinément 38,5 °C lorsque la température réelle est de 39 °C. Il sait discriminer l'état pathologique de l'état sain (la discrimination est préservée) mais il se trompe sur la mesure exacte de la gravité comme le calibrage est défaillant. Cette distinction n'est pas anecdotique : elle conditionne l'usage opérationnel du modèle.

Implications opérationnelles

Ainsi, selon l'objectif poursuivi, deux voies se dessinent. Si le modèle est destiné à un score d'octroi où seuls les rangs importent (sélectionner les 10 % dossiers les plus risqués), il est d'ores et déjà opérationnel. En revanche, si l'application requiert des probabilités non biaisées (provisionnement IFRS 9, pricing, stress testing), une étape de recalibration est impérative tels que par Platt scaling ou la régression isotonique afin de rétablir la correspondance entre prédictions et fréquences observées.

En conclusion, le déséquilibre de classes participe au défaut de calibrage sans en être l'unique responsable, et surtout, sans altérer la qualité discriminante du modèle. La coexistence d'une AUC élevée et d'un test de Hosmer-Lemeshow significatif n'est pas une pathologie statistique : elle reflète fidèlement la distinction entre classement relatif et estimation absolue. Loin d'invalider le modèle, ce diagnostic en précise les conditions de validité et oriente rigoureusement les décisions de recalibration.




Figure 3 : Performance du modèle logistique final – Courbe ROC

Source : Base de données HMEQ, traitements réalisés par les auteurs sous R

3. Construction du score cartographique (PDO) et analyse discriminante par déciles

a. Construction du score cartographique

La finalité d'un modèle de risque de crédit ne réside pas seulement dans sa précision statistique, mais surtout dans sa capacité à être interprété par des non-experts. Si la régression logistique produit une probabilité brute, celle-ci s'avère souvent complexe à manipuler pour les services opérationnels. C'est précisément pour cette raison que nous justifions la création d'un score cartographique : il permet de traduire une mesure abstraite en un outil d'aide à la décision intuitif, facilitant ainsi la communication entre les analystes risques et les chargés de clientèle.

Afin d'assurer cette transition, nous avons opté pour une transformation basée sur la logique des Points to Double the Odds (PDO). En fixant un score pivot à 600 points, nous utilisons la formule suivante : $\text{Score} = 600 - (20 / \ln(2)) \times \ln(p / (1 - p))$

Cette approche est particulièrement pertinente puisque, par construction, elle garantit qu'une variation fixe de points correspond à un doublement ou à une division par deux du risque. Il en résulte une échelle standardisée où la progression du score reflète une amélioration de la qualité de signature, offrant ainsi une lecture immédiate de la solvabilité de l'emprunteur.

L'efficacité de cette transformation est confirmée par l'analyse des boxplots sur l'échantillon de validation. En effet, l'examen de la distribution révèle que le groupe des non-défaillants ($n = 4771$) se concentre majoritairement au-dessus de 650 points, tandis que la population en défaut ($n = 1189$) subit un glissement structurel vers des valeurs inférieures, avec une médiane avoisinant les 625 points. Dans la mesure où les encoches (notches) des deux boîtes ne se chevauchent aucunement, nous pouvons affirmer avec un niveau de confiance de 95 % que le modèle parvient à isoler deux populations distinctes. Cette séparation nette prouve que le score n'est pas qu'une simple mise en forme esthétique, mais bien un indicateur robuste de la réalité du risque.

Par ailleurs, la fiabilité du dispositif est renforcée par la comparaison systématique des environnements SAS et R. Puisque le test de corrélation affiche un coefficient r supérieur à 0,99, la cohérence entre les deux moteurs de calcul est jugée parfaite, ce qui écarte tout risque d'erreur d'implémentation lors du passage en production.

En conclusion, bien qu'il subsiste naturellement une zone d'incertitude entre 620 et 660 points, la puissance discriminante du modèle permet d'établir des seuils de décision clairs. Dès lors, les dossiers dépassant 660 points peuvent faire l'objet d'une acceptation quasi automatique grâce à leur faible probabilité de défaut. À l'inverse, les scores inférieurs à 620 points signalent une dégradation telle du profil que le refus prioritaire s'impose, tandis que la zone intermédiaire justifie une expertise humaine complémentaire pour arbitrer les cas les plus ambigus.




Figure 4: Analyse de la capacité discriminante du score - Comparaison des distributions entre défaillants et non défaillants

Source : Base de données HMEQ, traitements réalisés par les auteurs sous R

b. Analyse de la performance par déciles et pouvoir discriminant

Afin d'éprouver la robustesse du score en conditions réelles, nous avons procédé à une analyse par déciles, segmentant l'ensemble de la population en dix groupes d'effectifs égaux ($n = 596$) classés par ordre croissant de score. Cette approche permet de vérifier concrètement si une hausse du score correspond systématiquement à une baisse du risque, validant ainsi la linéarité et la fiabilité de notre outil de décision.

L'examen du tableau des déciles révèle une performance remarquable puisque le taux de défaut décroît de manière quasi monotone à mesure que le score moyen augmente. En particulier, le premier décile, regroupant les scores les plus bas avec une moyenne de 574,75, concentre une part massive des sinistres avec un taux de défaut de 65,10 %. À l'inverse, les trois derniers déciles présentent des taux de défaut résiduels extrêmement faibles, oscillant entre 5,03 % et 5,70 %. Cette dynamique confirme que le score remplit parfaitement sa mission de

segmentation, en isolant les profils à haut risque dans les tranches inférieures de la distribution. (voir anexe)

Pour quantifier plus finement cette capacité de séparation, nous avons calculé l'Indice de Gini ainsi que l'Aire Sous la Courbe (AUC). L'Indice de Gini, qui s'élève à 0,4638, se situe dans la fourchette considérée comme performante et mature dans le secteur du crédit Retail, entre 0,40 et 0,50, ce qui indique que la courbe de Lorenz du modèle s'écarte significativement de la diagonale du hasard. De même, l'AUC, évaluée à 0,7319, confirme que dans plus de 73 % des cas, le modèle attribuera correctement un score plus faible à un client défaillant par rapport à un client sain choisi aléatoirement. Ces indicateurs mettent en évidence la puissance prédictive du modèle et sa capacité à différencier efficacement les profils à risque des profils sains.

En conclusion, la combinaison d'un taux de défaut élevé dans les premiers déciles et d'indicateurs de performance globale robustes valide pleinement l'aptitude du modèle à servir de base à une politique d'octroi automatisée. La structure observée des déciles montre que le risque est concentré plutôt que dispersé, ce qui permettrait à la banque de limiter le refus à une faible partie de la population, correspondant aux deux premiers déciles, tout en évitant la majorité des pertes financières potentielles. Ainsi, le modèle offre une segmentation fiable et exploitable pour la prise de décision en matière de crédit.




Figure 5: Courbe de Lorenz du modèle de scoring (PMM) et indice de Gini

Source : Base de données HMEQ, traitements réalisés par les auteurs sous R

IV. PARTIE 4 : VALIDATION CROISÉE ET APPROFONDISSEMENTS

1. Optimisation du seuil de décision pour l'arbitrage des risques

Dans le cadre de la mise en œuvre du modèle de scoring, l'utilisation d'un seuil de classification arbitraire à 0,50 s'avère souvent sous-optimale, particulièrement dans un contexte de gestion du risque de crédit où les coûts d'erreur sont asymétriques. L'objectif de cette étape est donc de calibrer précisément le curseur de décision afin de maximiser l'efficacité prédictive du modèle, en trouvant le point d'équilibre critique entre la détection des défauts (Rappel) et la précision des alertes (Précision).

a. Analyse de la dynamique des courbes

L'examen du graphique d'évolution des métriques révèle une asymétrie de performance fondamentale, matérialisée par un croisement précoce entre la courbe de rappel et celle de précision. À mesure que le seuil de décision augmente, le rappel chute brutalement, ce qui indique que le modèle génère des probabilités de défaut relativement faibles, même pour les dossiers présentant un risque avéré. Dès lors, l'utilisation du seuil standard de 0,50 (ligne grise) apparaît comme inefficace puisque, à ce niveau, le rappel est déjà fortement dégradé ; maintenir un tel curseur reviendrait à laisser passer une part critique du risque de crédit au sein du portefeuille.

b. Justification du seuil optimal à 0,23

Cette analyse nous conduit à identifier un point d'inflexion majeur où la courbe du F1-Score (en bleu) atteint son maximum, précisément à un seuil de 0,23. Le choix de ce seuil, matérialisé par la ligne violette, constitue un changement de paradigme pour la stratégie de décision car il privilégie le renforcement de la couverture du risque. En abaissant ainsi le curseur, nous augmentons significativement le taux de détection des mauvais payeurs, adoptant de fait une posture prudente qui donne la priorité à la protection du capital.

Certes, cette orientation implique un coût d'opportunité via une légère augmentation du taux de rejet des dossiers sains, consécutive à la baisse de la précision. Toutefois, d'un point de vue bancaire, le coût d'un défaut réel est généralement bien supérieur à la perte de marge d'intérêt d'un client refusé à tort. Par ailleurs, la robustesse de la spécificité à ce niveau de seuil garantit que la grande majorité des bons dossiers continue d'être acceptée, validant ainsi l'alignement de la performance statistique avec une stratégie de gestion des risques rigoureuse.




Figure 6 : Analyse des performances selon le seuil de classification – Sélection du seuil optimal

Source : Base de données HMEQ, traitements réalisés par les auteurs sous R

2. Analyse non-linéaire du risque : Arbre de décision

Dans une logique de comparaison avec l'approche paramétrique précédente, l'arbre de décision constitue une alternative non linéaire permettant de capturer des interactions complexes entre variables sans hypothèse préalable sur la forme fonctionnelle. La structure estimée traduit un compromis entre capacité prédictive et maîtrise du surapprentissage, tout en restant lisible pour être interprétée dans une perspective réglementaire.

L'examen du nœud racine montre que la variable DELINQ constitue le premier facteur de segmentation, confirmant l'intuition métier déjà observée dans la régression logistique : l'historique de délinquance est le déterminant principal du risque de défaut. Dès le premier split, l'arbre isole une population significativement plus risquée, traduisant une forte capacité de séparation. Cette hiérarchisation endogène des variables renforce la cohérence économique du

modèle, puisque les incidents passés sont naturellement les meilleurs prédicteurs du comportement futur.

Les niveaux inférieurs de l'arbre mettent en évidence des interactions pertinentes entre comportement passé, pression financière et stabilité du profil. Les variables telles que CLAGE, NINQ, DEROG ou certaines modalités professionnelles interviennent successivement pour affiner la segmentation. Cette logique séquentielle permet de construire des sous-populations homogènes en termes de risque, ce qui constitue l'objectif d'un outil de scoring en production. Contrairement à la régression logistique qui agrège les effets de manière additive, l'arbre révèle des effets conditionnels : l'impact d'une variable dépend explicitement du chemin déjà emprunté dans la structure.

L'analyse des feuilles confirme cette capacité de concentration du risque. Certaines présentent une séparation quasi parfaite entre défaut et non-défaut sur des segments spécifiques, tandis que d'autres affichent des zones de forte incertitude où le pouvoir discriminant reste limité. Cette hétérogénéité est typique des modèles arborescents et rappelle que la performance globale repose sur l'équilibre entre segments très purs et segments plus ambigus.

Les contraintes imposées sur le nombre minimal d'observations par segment évitent la création de sous-populations trop fines et instables, ce qui assure une granularité cohérente avec une utilisation en environnement bancaire, où la robustesse prime sur la simple performance in-sample.

D'un point de vue stratégique, cet arbre confirme plusieurs enseignements clés. Premièrement, le risque est fortement concentré autour des variables comportementales, validant l'importance de l'historique de crédit dans la politique d'octroi. Deuxièmement, la présence de segments très purs suggère que certaines règles décisionnelles simples pourraient être dérivées à des fins opérationnelles. Cependant, la présence de segments à forte impureté indique que l'arbre seul pourrait manquer de stabilité face à des variations macroéconomiques, ce qui plaide en faveur d'une utilisation complémentaire avec des modèles paramétriques ou d'ensemble.

En définitive, cette modélisation par arbre de décision apporte une lecture non linéaire et interprétable du risque de crédit. Elle met en évidence des interactions structurantes entre comportement passé, capacité financière et stabilité socio-professionnelle, tout en maintenant une architecture contrôlée compatible avec les exigences de gouvernance des modèles internes. Dans une perspective industrielle, elle constitue ainsi un outil pertinent, soit comme benchmark

de la régression logistique, soit comme composant d'une approche plus avancée de type ensemble learning.




Figure 7 : Modèle d'arbre de décision – Identification des profils à risque de défaut

Source : Base de données HMEQ, traitements réalisés par les auteurs sous R

V. PARTIE 5 : MODÉLISATION PRÉDICTIVE COMPARATIVE

1. Traitement du déséquilibre des classes par SMOTE

L'un des défis majeurs de la modélisation du risque de crédit réside dans le déséquilibre naturel des classes. En effet, dans notre jeu de données, la proportion de défauts s'élève à 19,8 %, ce qui signifie que les "bons" payeurs sont largement majoritaires par rapport aux "mauvais". Sans traitement approprié, ce déséquilibre biaiserait l'apprentissage des algorithmes, les incitant à privilégier systématiquement la classe majoritaire et à pénaliser la détection des défauts.

Pour pallier cette difficulté, nous avons eu recours à la technique SMOTE (Synthetic Minority Oversampling Technique). Cette méthode, développée par Chawla et al. (2002), ne se contente pas de dupliquer aléatoirement les observations de la classe minoritaire. Elle génère synthétiquement de nouveaux exemples de défauts en interpolant entre les individus existants.

Pour chaque observation de la classe minoritaire, SMOTE identifie ses k plus proches voisins et crée un nouvel exemple synthétique le long du segment reliant ces points dans l'espace des caractéristiques. Cette approche présente l'avantage majeur de produire des échantillons réalistes et diversifiés, évitant le sur-apprentissage lié à la simple duplication.

Distribution avant SMOTE:

- Classe 0 (bons): 3340
- Classe 1 (défauts): 832
- Ratio: 1:4.0

Distribution après SMOTE:

- Classe 0 (bons): 3340
- Classe 1 (défauts): 3340
- Ratio: 1:1 (équilibré)

Échantillonnage synthétique (SMOTE) effectué

Figure 8 : Distribution des classes avant et après suréchantillonnage synthétique (SMOTE)

Source : Base de données HMEQ, traitements réalisés par les auteurs sous Python

Cet équilibrage est crucial car il permet aux algorithmes d'apprendre à détecter les signaux faibles de la classe minoritaire sans être submergés par la majorité. Pour évaluer nos modèles dans ce contexte, nous avons privilégié des métriques robustes au déséquilibre, notamment le Recall (sensibilité) qui mesure la capacité à capturer les vrais défauts, et l'AUC-ROC qui évalue la discrimination globale indépendamment du seuil choisi.

2. Benchmark des algorithmes : Régression Logistique, Arbre, Gradient Boosting, XGBoost

Avant d'analyser les résultats, il convient de définir les indicateurs clés utilisés pour cet audit de performance :

- L'AUC-ROC : Mesure la capacité globale du modèle à distinguer les clients sains des clients en défaut. Plus elle est proche de 1, plus le modèle est robuste.
- Le Recall (Sensibilité) : Capacité à capter les vrais défauts. C'est la métrique vitale ici car, pour une banque, rater un client insolvable (Faux Négatif) est bien plus coûteux que de refuser par erreur un bon client.

- Le F1-Score : Moyenne harmonique entre précision et rappel, offrant une vue équilibrée de la performance.
- La Matrice de Confusion : Confrontation directe entre les prédictions et la réalité (Vrais Positifs, Faux Négatifs, etc.).
- Feature Importance : Analyse du poids accordé à chaque variable dans la prise de décision du modèle.

a. Gradient Boosting : L'excellence statistique

Le Gradient Boosting repose sur un apprentissage séquentiel où chaque nouvel arbre corrige les erreurs de prédiction des précédents. Avec un AUC de 0,8334, il s'impose comme le modèle le plus équilibré du benchmark. Sa matrice de confusion sur le test révèle une efficacité remarquable avec 1 285 vrais négatifs et 213 vrais positifs. En termes de Feature Importance, le modèle place les incidents de paiement (DELINQ) comme pilier central de sa décision, suivis du nombre de demandes de crédit récentes (NINQ) et de l'ancienneté du crédit (CLAGE), confirmant ainsi que le comportement historique prime sur le patrimoine.

b. XGBoost : La précision

Variante optimisée du boosting, XGBoost affiche des performances quasi-identiques au leader avec un AUC de 0,8290. Il se distingue toutefois par le Recall le plus élevé des modèles de Machine Learning (0,6022), identifiant correctement 215 défauts. Sa hiérarchie des variables est intéressante car, bien que DELINQ reste prédominant, il accorde une importance singulière aux variables professionnelles (JOB_Other, JOB_Office). Cela suggère que XGBoost parvient à extraire des signaux plus fins des catégories socio-professionnelles pour affiner ses prédictions.

c. Régression logistique : Le standard prudentiel


Ce modèle probabiliste classique est très apprécié pour sa transparence (interprétation par les Odds Ratios). Bien que son AUC (0,7671) soit en retrait, il surprend par un Recall exceptionnel de 0,6303 (225 défauts captés). Toutefois, la matrice de confusion montre un coût élevé : 347 faux positifs, soit autant de clients sains injustement rejetés. Son analyse d'importance est

radicalement différente, se focalisant massivement sur les catégories d'emploi (JOB_Unknown, JOB_Sales) plutôt que sur les ratios financiers directs, ce qui explique son manque de précision globale par rapport au boosting.


d. Arbre de décision : La lisibilité opérationnelle

L'arbre de décision segmente la population par des règles binaires simples. Malgré sa valeur pédagogique, il est ici le moins performant avec un AUC de 0,7400 et un Recall de 0,5154. Sa matrice de confusion laisse passer 173 défauts (Faux Négatifs), un risque inacceptable en production. Son analyse d'importance est la plus "monolithique", où la variable DELINQ écrase tous les autres prédicteurs, montrant une incapacité à intégrer la subtilité des autres signaux comme le font les modèles d'ensemble.


Comparaison Train vs Test - Régression Logistique




Comparaison Train vs Test - Arbre de Décision



Comparaison Train vs Test - XGBoost



Comparaison Train vs Test - Gradient Boosting



Source : Base de données HMEQ, traitements réalisés par les auteurs sous Python

3. Évaluation des performances : AUC-ROC, Recall, Matrices de confusion

L'évaluation comparative des quatre modèles permet de dresser un panorama précis de leurs forces et faiblesses respectives au regard des métriques de performance.

Synthèse des indicateurs clés

Tableau X : Comparaison des performances des modèles - Échantillon test

Modèle	Accuracy	Precision	Recall	F1-score	AUC-ROC	CV F1
Régression logistique	0.732	0.393	0.630	0.484	0.767	0.721 (±0.009)
Arbre de décision	0.771	0.438	0.515	0.474	0.740	0.773 (±0.012)
Gradient Boosting	0.838	0.593	0.597	0.595	0.833	0.869 (±0.010)
XGBoost	0.838	0.592	0.602	0.597	0.829	0.859 (±0.008)

Source : Base de données HMEQ, traitements réalisés par les auteurs sous Python

- Analyse des matrices de confusion

La matrice de confusion du Gradient Boosting révèle une efficacité remarquable avec 1 285 vrais négatifs et 213 vrais positifs, témoignant d'un excellent équilibre entre la détection des défauts et la préservation des bons dossiers.

XGBoost se distingue par le Recall le plus élevé des modèles de Machine Learning (0,6022), identifiant correctement 215 défauts, ce qui en fait un outil particulièrement adapté pour une stratégie de couverture maximale du risque.

La Régression Logistique, bien qu'affichant un Recall exceptionnel de 0,6303 (225 défauts captés), présente un coût élevé avec 347 faux positifs, soit autant de clients sains injustement rejetés. Ce constat illustre le trade-off inhérent à la modélisation : une sensibilité accrue se paie souvent par une perte de précision.

L'Arbre de Décision confirme sa position de lanterne rouge avec une matrice de confusion qui laisse passer 173 défauts (Faux Négatifs), un niveau de risque inacceptable dans un contexte de production bancaire où chaque défaut non détecté représente une perte financière potentielle.

4. Interprétation des modèles et analyse de l'importance des variables

L'analyse de l'importance des variables (Feature Importance) permet de comprendre la logique décisionnelle de chaque algorithme et de vérifier la cohérence économique des modèles.

Gradient Boosting :

a. la hiérarchie naturelle du risque

Le Gradient Boosting place les incidents de paiement (DELINQ) comme pilier central de sa décision. Cette variable est suivie du nombre de demandes de crédit récentes (NINQ) et de l'ancienneté du crédit (CLAGE). Cette hiérarchie confirme un enseignement majeur de notre analyse : le comportement historique de l'emprunteur prime très nettement sur les variables patrimoniales dans l'explication du risque de défaut. La présence de NINQ en seconde position souligne également l'importance de la "faim de crédit" comme signal d'alerte.

b. XGBoost : la finesse d'analyse des profils professionnels

Si DELINQ reste prédominant dans XGBoost, l'algorithme accorde une importance singulière aux variables professionnelles (JOB_Other, JOB_Office). Cette caractéristique suggère que XGBoost, grâce à sa mécanique d'optimisation plus avancée, parvient à extraire des signaux plus fins des catégories socio-professionnelles pour affiner ses prédictions. L'algorithme détecte ainsi des interactions subtiles entre le métier exercé et la probabilité de défaut que les autres modèles peinent à capturer.

c. Régression Logistique : une vision différente du risque

L'analyse d'importance de la régression logistique est radicalement différente. Le modèle se focalise massivement sur les catégories d'emploi (JOB_Unknown, JOB_Sales) plutôt que sur les ratios financiers directs. Cette particularité explique son manque de précision globale par rapport aux modèles de boosting : en surpondérant l'effet des variables catégorielles, la régression logistique perd en finesse dans l'évaluation continue du risque porté par les variables comportementales. Cette orientation reflète toutefois sa nature paramétrique, qui cherche à établir des relations linéaires stables plutôt qu'à optimiser localement la prédiction.

d. Arbre de Décision : la vision monolithique

L'analyse d'importance de l'arbre de décision est la plus "monolithique". La variable DELINQ écrase littéralement tous les autres prédicteurs, montrant une incapacité structurelle à intégrer la subtilité des autres signaux comme le font les modèles d'ensemble. Cette caractéristique, bien que pénalisante pour la performance globale, présente l'avantage d'une lisibilité parfaite : la

règle métier "les incidents passés prédisent les défauts futurs" est ici érigée en principe unique de segmentation.

e. Conclusion et Choix du Modèle Final

Le Gradient Boosting est retenu comme le meilleur modèle. Ce choix est justifié par le meilleur arbitrage entre la capacité de discrimination globale ($AUC = 0,8334$) et une stabilité remarquable confirmée par la validation croisée ($CV F1 : 0,8686$). Bien que la Régression Logistique offre un Recall brut supérieur, le Gradient Boosting est plus "juste" commercialement en évitant un volume excessif de faux refus.

Forces et faiblesses des challengers :

- XGBoost : Excellente alternative, très robuste face aux données manquantes, mais légèrement moins stable sur notre jeu de données que le Gradient Boosting.
- Régression Logistique : Indispensable pour le reporting réglementaire grâce à sa transparence, mais trop "sévère" et rigide sur les frontières de décision complexes.
- Arbre de Décision : Excellent outil de communication pour expliquer une décision à un client, mais trop imprécis pour servir de moteur de scoring principal.

CONCLUSION ET PERSPECTIVES

Ce projet de scoring multi-environnement a permis de construire un outil décisionnel à la fois robuste, performant et interprétable, répondant pleinement à la problématique initiale : comment mobiliser de manière complémentaire les environnements SAS, R et Python pour élaborer un score de crédit fiable. Le parcours depuis le diagnostic des données jusqu'à la modélisation comparative a confirmé l'intérêt d'une approche intégrée.

La phase de diagnostic sous SAS a souligné l'importance cruciale de la gestion des données manquantes, avec un taux d'omission de 26,99 % sur DEBTINC, justifiant l'imputation par MICE-PM. L'analyse exploratoire a révélé la hiérarchie des facteurs de risque, plaçant les variables comportementales telles que DELINQ et DEROG au cœur du pouvoir discriminant. La modélisation logistique a fourni un socle interprétable et conforme aux exigences prudentielles, tandis que la cartographie du score a transformé cette mesure abstraite en un outil opérationnel et intuitif. Enfin, le benchmark réalisé sous Python a mis en évidence la supériorité

du Gradient Boosting, avec une AUC de 0,8334, tout en réaffirmant la valeur de la régression logistique pour la transparence réglementaire.

L'évaluation par déciles confirme l'aptitude du modèle à guider une politique d'octroi automatisée : le premier décile concentre la majorité des sinistres, tandis que les derniers déciles présentent des taux de défaut très faibles. Cette concentration du risque permet à la banque de cibler précisément les décisions de refus tout en limitant l'exposition financière.

Plusieurs perspectives d'amélioration émergent naturellement de cette étude. L'intégration de sources de données complémentaires, qu'il s'agisse d'informations macroéconomiques, de comportements clients plus détaillés ou de variables de relation bancaire, pourrait renforcer le pouvoir prédictif du modèle. L'exploration d'algorithmes plus sophistiqués, tels que LightGBM, CatBoost ou des réseaux de neurones profonds, offrirait la possibilité de capturer des non-linéarités complexes et de tester des architectures hybrides combinant régression logistique et arbres de décision. La robustesse temporelle pourrait être consolidée par la mise en place de back-testing sur plusieurs années, l'intégration de mécanismes d'apprentissage continu et la simulation de scénarios de stress macroéconomique. Enfin, l'interprétabilité, essentielle dans un cadre réglementaire strict, pourrait être approfondie grâce à des méthodes explicatives comme SHAP ou LIME, à des dashboards interactifs pour les équipes opérationnelles et à une documentation systématique des limites et conditions de validité du modèle.

En somme, ce projet démontre que la combinaison des environnements SAS, R et Python constitue une approche puissante pour le scoring de crédit, offrant à la fois performance, transparence et adaptabilité. Les pistes d'amélioration proposées ouvrent la voie à un outil encore plus robuste et pertinent, capable de s'inscrire durablement dans un processus décisionnel automatisé et réglementairement conforme.

ANNEXES

Annexe 1 : Répartition des défauts par décile de score


<i>Décile</i>	<i>N</i>	<i>N défauts</i>	<i>Taux défaut</i>	<i>Score min</i>	<i>Score max</i>	<i>Score moyen</i>
<i>1</i>	596	388	0.6510	336.7770	607.9893	574.7467
<i>2</i>	596	242	0.4060	608.1052	626.9880	618.7419
<i>3</i>	596	157	0.2634	627.0024	637.3688	632.4263
<i>4</i>	596	105	0.1762	637.4102	645.6982	641.7387
<i>5</i>	596	83	0.1393	645.7104	652.8493	649.4151
<i>6</i>	596	57	0.0956	652.8539	659.7442	656.4342
<i>7</i>	596	59	0.0990	659.7455	666.3192	663.0213
<i>8</i>	596	34	0.0570	666.3372	674.1317	670.0188
<i>9</i>	596	30	0.0503	674.1458	683.1888	678.3627
<i>10</i>	596	34	0.0570	683.2355	829.2976	696.6276

Source : Base de données HMEQ, traitements réalisés par les auteurs sous R

Annexe 2 : Comparaison des performances des modèles - Échantillon d'entraînement


Modèle	Accuracy	Precision	Recall	F1-score	AUC-ROC
Régression logistique	0.752	0.426	0.698	0.529	0.802
Arbre de décision	0.787	0.472	0.563	0.513	0.782
Gradient Boosting	0.875	0.680	0.701	0.690	0.909
XGBoost	0.867	0.664	0.678	0.671	0.899

Source : Base de données HMEQ, traitements réalisés par les auteurs sous Python




Annexe 3 : Distribution de la variable cible et déséquilibre des classes

Source : Base de données HMEQ, traitements réalisés par les auteurs sous Python




Annexe 4 : Distribution des montants de prêt (LOAN)

Source : Base de données HMEQ, traitements réalisés par les auteurs sous Python




Annexe 5 : Distribution de la valeur des biens immobiliers (VALUE)

Source : Base de données HMEQ, traitements réalisés par les auteurs sous Python




Annexe 6 : Distribution du montant hypothécaire restant dû (MORTDUE)

Source : Base de données HMEQ, traitements réalisés par les auteurs sous Python




Annexe 7 : Distribution du ratio d'endettement (DEBTINC)

Source : Base de données HMEQ, traitements réalisés par les auteurs sous Python




Annexe 8 : Distribution du nombre d'incidents passés (DELINQ)

Source : Base de données HMEQ, traitements réalisés par les auteurs sous Python




Annexe 9 : Distribution des défauts majeurs antérieurs (DEROG)

Source : Base de données HMEQ, traitements réalisés par les auteurs sous Python




Annexe 10 : Distribution des demandes de crédit récentes (NINQ)

Source : Base de données HMEQ, traitements réalisés par les auteurs sous Python



Annexe 11 : Distribution de l'ancienneté de la ligne de crédit la plus ancienne (CLAGE)

Source : Base de données HMEQ, traitements réalisés par les auteurs sous Python



Annexe 12 : Distribution de l'ancienneté dans l'emploi (YOJ)

Source : Base de données HMEQ, traitements réalisés par les auteurs sous Python